

**Centro Universitario de Ciencias Exactas e Ingenierías**

**Ingeniería en Computación**

**Práctica 1 ejercicio 3**



**PRESENTA:**

**Ramirez Gutierrez Hugo Vladimir**

**Código: 220287144**

**Materia:**

**Seminario de Solución de problemas de Inteligencia Artificial 2**

**Docente: Diego Campos Pena**

**Índice:**

Introducción	3
Desarrollo	3
Resultados	4
Conclusión	5

## Introducción:

En este reporte, se aborda la implementación de redes neuronales multicapa para la clasificación de datos utilizando dos funciones de activación populares: la función sigmoide y la función ReLU (Rectified Linear Unit). Las redes neuronales multicapa son un tipo de modelo de aprendizaje profundo que consiste en múltiples capas de neuronas interconectadas, donde cada neurona utiliza una función de activación para introducir no linealidad en el modelo. En este estudio, se exploran las características y el rendimiento de estas redes neuronales en la clasificación de un conjunto de datos.

## Desarrollo:

El código implementa dos clases de funciones de activación, ``sigmoid`` y ``relu``, junto con sus respectivas derivadas, ``sigmoid_derivative`` y ``relu_derivative``. A continuación, se define la clase ``NeuralNetwork``, que representa una red neuronal multicapa con la capacidad de entrenar y predecir datos de entrada. Se proporcionan métodos para la propagación hacia adelante y hacia atrás, así como para el entrenamiento y la predicción de la red.

El conjunto de datos se carga desde un archivo CSV y se divide en características (X) y etiquetas (y). Se definen dos arquitecturas de red neuronal: una con funciones de activación sigmoideas y otra con funciones de activación ReLU. Ambas redes se entrenan con el conjunto de datos de entrada utilizando el algoritmo de descenso de gradiente durante un número especificado de épocas.

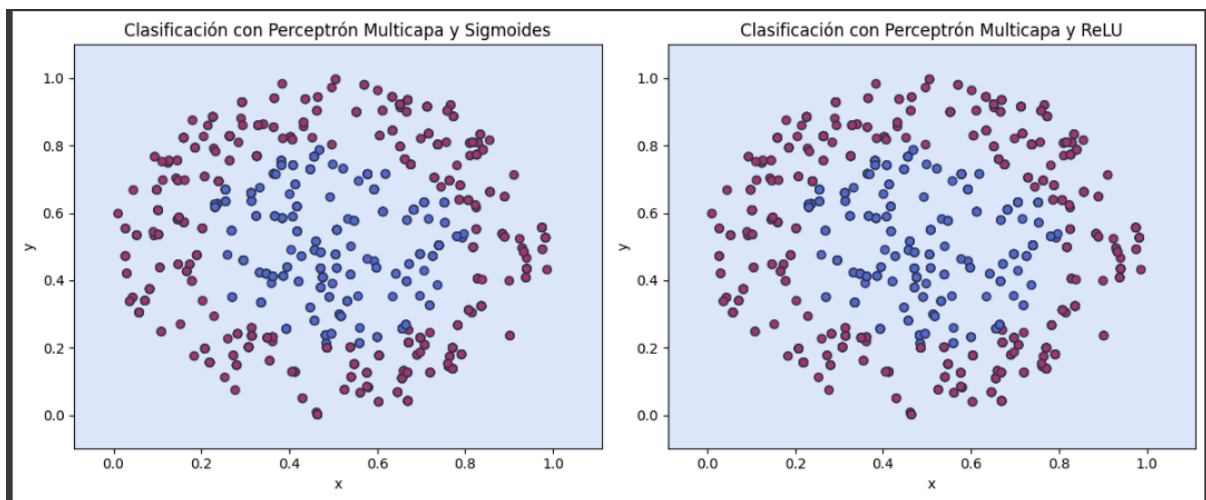
Finalmente, se generan gráficas para visualizar las regiones de decisión resultantes de cada red neuronal. Estas gráficas muestran cómo cada red clasifica los datos de entrada y proporcionan una comparación visual de su rendimiento.

## Resultados:

Es posible que las gráficas de las regiones de decisión generadas por las redes neuronales con diferentes funciones de activación puedan parecer similares en algunos casos. Esto podría ocurrir si los datos son linealmente separables o si las relaciones entre las características son simples y fáciles de aprender para ambas funciones de activación.

Sin embargo, incluso si las gráficas parecen similares en términos de las regiones de decisión, aún puede haber diferencias sutiles en la forma en que las redes neuronales con diferentes funciones de activación están modelando los datos. Estas diferencias pueden no ser evidentes simplemente al observar las gráficas, pero pueden afectar el rendimiento de la red en otros conjuntos de datos o en escenarios más complejos.

Por lo tanto, aunque las gráficas puedan parecer similares en algunos casos, sigue siendo importante considerar las diferencias en las funciones de activación y cómo estas pueden afectar el comportamiento y la capacidad de generalización de la red neuronal en una variedad de situaciones.



## **Conclusiones:**

En conclusión, la implementación y visualización de redes neuronales multicapa con diferentes funciones de activación proporciona una comprensión más profunda de cómo estas funciones afectan el rendimiento de la red en la clasificación de datos. A través de este estudio, se puede observar cómo las regiones de decisión generadas por cada función de activación difieren y cómo influyen en la capacidad de la red para modelar relaciones no lineales en los datos. Esta exploración puede ser útil para la selección y ajuste adecuado de la arquitectura de la red neuronal en problemas de clasificación específicos.